

→ A partir de esta
sesión...
La Empresa va a
converger con lo
que está
veniendo Enrique.

Intro. Finanzas y Empresa

Eduardo Martínez

Universidad Nacional Autónoma de México

Sesión: 7 de abril de 2026


Portafolio de mínima varianza

$\mathbf{r} = (r_1, r_2, \dots, r_n)^T$ activos riesgosos

$\mathbb{E}(\mathbf{r}) = (\mathbb{E}(r_1), \dots, \mathbb{E}(r_n))^T$

Mini-reposo

Matriz de cov Σ



Un portafolio

$$r = \alpha_1 r_1 + \alpha_2 r_2 + \dots + \alpha_n r_n$$

$$\alpha_1 + \alpha_2 + \dots + \alpha_n = 1$$

$$\hookrightarrow r = \alpha^T \mathbf{r}$$

$$1 = \alpha^T \mathbf{1}$$

Portafolio especial

$\min_{\alpha} \text{Var}(r)$

α

s.a.

$$\alpha^T \mathbf{1} = 1$$

$$\alpha_{mv} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}$$

problema potencial.

Portafolio de tangencia

→ otro portafolio especial.

Obj 1:

Encontrar portaf con menor riesgo

Idea básica:

Incluir un activo libre de riesgo (r_f)


↳ se encuentra portaf en la recta roja

¿Qué caracteriza al portaf de tangencia
→ máximo Sharpe ratio

$$SR(r) = \frac{E(r) - r_f}{\sigma_r}$$

$$\max_{\alpha} \frac{E(r) - r_f}{\sigma_r}$$


$$\text{s.t. } \alpha^T \mathbf{1} = 1$$



¿qué definen A y B?
A y B son
para el mismo
nivel de rend esp.
pero con
diferente
riesgo.

$$\alpha_T = \frac{\Sigma^{-1} [E(\mathbf{r}) - r_f \mathbf{1}]}{\mathbf{1}^T \Sigma^{-1} [E(\mathbf{r}) - r_f \mathbf{1}]}$$

Teorema de dos fondos → Pendiente p/ Enrique



Objetivo: Encontrar
un portaf con
rendim esp. r_{obt}
y mínima varianza




Se puede resolver
explícitamente

∴

pero es un libro

Teo de 2 fondos: Puedes construir el portaf C como una
combinación lineal de los port A y B y sigue siendo
óptimo.



Teoría CAPM

Proposición (Teorema CAPM):

Si el portafolio de mercado es equivalente al portafolio de tangencia, entonces para cualquier activo con rendimiento r_i se satisface que

$$\mathbb{E}(r_i) - r_f = \rho_{i,m} \cdot \frac{\sigma_i}{\sigma_m} (\mathbb{E}(r_m) - r_f), \quad (1)$$

donde $\rho_{i,m}$ es el coeficiente de correlación entre r_i y r_m ; y σ_m es la desviación estándar del rendimiento del portafolio de mercado.

- Pero se definió el concepto de beta de un activo: Para un activo con rendimiento r , se define el factor β (o coeficiente β) con respecto al portafolio de mercado como

$$\beta := \frac{Cov(r, r_m)}{Var(r_m)}.$$

Teoría CAPM

Con esto, se puede reescribir el Teorema CAPM como

$$\mathbb{E}(r_i) - r_f = \beta_i (\mathbb{E}(r_m) - r_f), \quad (2)$$

Generalización:

Si el portafolio de mercado es equivalente al portafolio de tangencia, para cualquier activo con rendimiento r_i existe una variable aleatoria ϵ_i tal que

(a) Satisface la relación

$$r_i - r_f = \beta_i [r_m - r_f] + \epsilon_i, \quad (3)$$

$$\text{con } \beta_i = \frac{\text{Cov}(r_i, r_m)}{\text{Var}(r_m)}.$$

(b) $\mathbb{E}(\epsilon_i) = 0$

(c) $\text{Cov}(\epsilon_i, r_m) = 0$

Si ϵ_i es grande significa que la relación con el portafolio de mercado no alcanza para explicar el rendim.

relación entre valores esperados.

cte para todos los participantes del mercado.

regresión: término de error

En fincas, es el volumen que no alcanza a explicar el portafolio de mercado.

El mercado mexicano

 ± 130 acciones

AC.MX	ACCELSAB.MX	ACTINVRB.MX	AGRIEXPA.MX	AGUA.MX
AGUILASCPO.MX	AHMSA.MX	ALFAA.MX	ALPEKA.MX	ALSEA.MX
ALTERNA.MX	AMX.MX	ANB.MX	ARA.MX	ARISTOSA.MX
ASURB.MX	AUTLANB.MX	AXTELCPO.MX	AZTECAPCO.MX	BBAJIOO.MX
BBVA.MX	BEVIDESB.MX	BIMBOA.MX	BOLSA.MX	CABLECPO.MX
CADUA.MX	CEMEXCPO.MX	CHDRAUIB.MX	CIEB.MX	CIDMEGA.MX
CMOCTEZ.MX	CMRB.MX	COLLADO.MX	CONVERA.MX	CREAL.MX
CTALPEKA.MX	CTAXTELA.MX	CUERVO.MX	CULTIBAB.MX	CYDSASAA.MX
DIABLOSO.MX	DINEB.MX	EDOARDO3.MX	ELEKTRA.MX	FINAMEXO.MX
FINDEP.MX	FRAGUAB.MX	FRES.MX	GAPB.MX	GAVA.MX
GBMO.MX	GCARSOA1.MX	GCC.MX	GENTERA.MX	GFAMSA.MX
GFINBURO.MX	GFMULTIO.MX	GFNORTEO.MX	GICSAB.MX	GIGANTE.MX
GISSAA.MX	GMD.MX	GMEXICOB.MX	GMXT.MX	GNP.MX
GOMO.MX	GPH1.MX	GPROFUT.MX	GRUMBAB.MX	HCITY.MX
HERDEZ.MX	HIMEXSAA.MX	HOMEX.MX	HOTEL.MX	IASASA.MX
ICA.MX	ICHB.MX	IDEALB-1.MX	INVEXA.MX	KIMBERA.MX
KOF.MX	KOFUBL.MX	KUOB.MX	LABB.MX	LACOMERUBC.MX
LAMOSA.MX	LASEG.MX	LASITE.MX	LIVEPOL1.MX	MEDICAB.MX
MEGACPO.MX	MFRISCOA-1.MX	MINSAB.MX	NEMAKA.MX	OMAB.MX
ORBIA.MX	PASAB.MX	PE&OLES.MX	PINFRA.MX	POCHTECB.MX
POSADASA.MX	PLANI.MX	PROCORPB.MX	PV.MX	Q.MX
QBINDUSA.MX	QUMMAB.MX	RCENTROA.MX	RA.MX	RLHA.MX
SAREB.MX	SAVIAA.MX	SIMECB.MX	SITES1A-1.MX	SORIANAB.MX
SPORTS.MX	TEAKCPO.MX	TEKCHEMA.MX	TLEVISACPO.MX	TMMA.MX
TRAXIONA.MX	TS.MX	UNIFINA.MX	VALUEGFO.MX	VASCONI.MX
VESTA.MX	VINTE.MX	VISTAA.MX	VITROA.MX	VOLARA.MX

El problema de estimación

- Para cada uno de los activos anteriores, se cuenta con un histórico de precios en el tiempo $\{P_{i,t}\}_{t=0}^T$
- Con dicho histórico, se obtiene el histórico de log-rendimientos $\{r_{i,t}\}_{t=1}^T$, donde

$$r_{i,t} := \log \left(\frac{P_{i,t}}{P_{i,t-1}} \right)$$

lo sacamos de Yahoo Finance

$$P_{i,t} = P_{i,t-1} \cdot e^{r_{i,t}}$$

- Clásicamente, con este histórico se busca una estimación de $\mathbb{E}(r_i)$ y $Var(r_i)$ $\rightarrow$ ya lo hicieron en Finance.
- También se tiene un histórico del portafolio de mercado, el IPC (su ticker es " $\wedge MXX$ "), y sus correspondientes log-rendimientos

$$\{P_{IPC,t}\}_{t=0}^T, \quad r_{IPC,t} := \log \left(\frac{P_{IPC,t}}{P_{IPC,t-1}} \right)$$

Índice de precios y cotizaciones

- Clásicamente, con este histórico se busca una estimación de $\mathbb{E}(r_m)$ y $Var(r_m)$

El problema de estimación

- Como se cuenta con n activos, con el histórico de vectores

$$\{(r_{1,t}, r_{2,t}, \dots, r_{n,t})\}_{i=1}^T$$

se busca estimar Σ . $\rightarrow$ matriz de varianzas y cov. $\rightarrow$ ya lo hicimos en clase.

- A partir de n modelos de regresión lineal simple

≈ 130

$$r_i - r_f = \gamma_i + \beta_i(r_m - r_f) + \epsilon_i$$

para estimar β_i

se obtienen estimaciones de $\gamma_1, \gamma_2, \dots, \gamma_n$ y $\beta_1, \beta_2, \dots, \beta_n$

- Para verificar si el Teorema CAPM se cumple, se hacen n pruebas de hipótesis del tipo

$$H_0 : \gamma_i = 0, \quad \text{v.s.} \quad H_a : \gamma_i \neq 0$$

Estimar si es que un $\gamma_i \neq 0$
ya no se cumple el CAPM


El problema de datos

¿por qué no entra
basura a nuevos
datos?

El clásico GIGO

La calidad del output está determinada por la calidad del input: "Garbage In, Garbage Out".

Para el activo i , se puede tener descargas del histórico de la forma



El problema de datos

- Esto hace que el conjunto de datos (el input)

$$\begin{bmatrix} r_{1,1} & r_{2,1} & \dots & r_{n,1} \\ r_{1,2} & r_{2,2} & \dots & r_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ r_{1,T} & r_{2,T} & \dots & r_{n,T} \end{bmatrix}$$

+ 130
columns

garbage act.

tenga mala calidad.

- Además se quiere que T sea suficientemente grande para confiar en los estimadores.

El problema de datos

- ¿Porqué pasa?
- Las empresas cambian de ticker: de "EMPRESA.MX" a "EMPRESITA.MX" y la API que se está usando no los homologa y peor aún, deja de tener disponibles los de "EMPRESA.MX".
- Las empresas no cotizan algunos días y se obtienen los NAs
- Las empresas no cotizan algunos días y la API que se está usando repite la última cotización, dando origen a rachas de precios repetidos $P_{i,1}, P_{i,2}, \dots, P, P, P, \dots, P_{i,T}$

El problema de datos

¿cómo se resuelve?

- Inspección, inspección e inspección.
- El proceso es un poco manual.
- Mientras más podamos automatizar, MEJOR
- Investigar los cambios de tickers y juntar los históricos "manualmente".
- Si las rachas de NAs o repetidos son cortas y pocas, podemos vivir con ello.
- Si las rachas de NAs o repetidos son largas, se recomienda no incluir a esa empresa en el análisis.
- Encontrar un equilibrio entre n y T ... De nuevo el *No Free Lunch (NFL) Theorem*!!!
- Por supuesto, todo este proceso se documenta, se justifica y reporta.

e intentar construir una rutina de validación } Enigme.
¡Tarea de Enigme!

Modelo de un índice

Hpt $\text{portafolio} = \text{port mercado}$.

- Si no se cumple el CAPM, i.e. $\gamma_i \neq 0$ para algunas i 's, se tendrán que hacer más suposiciones... El modelo de un índice.

- Se expresará

$$r_i - r_f = \gamma_i + \beta_i(r_m - r_f) + \epsilon_i,$$

riesgo sistemático

riesgo idiosincrático
específico.

donde $\mathbb{E}(\epsilon_i) = 0$ y $Cov(\epsilon_i, r_m) = 0$

- El modelo de un índice preserva la estructura de descomposición entre componentes sistemáticos e idiosincráticos para cada activo individual.
- PEEEEERO agrega una suposición que permite caracterizar completamente la estructura de covarianzas entre todos los activos: Los rendimientos residuales de activos distintos están no correlacionados, i.e. los ϵ_i 's no están correlacionados.

Modelo de un índice

Notación.

- Considérese n activos riesgosos cuyos rendimientos en exceso respecto a la tasa libre de riesgo se denotan como

$$\mathbf{r} - r_f \mathbf{1} = (r_1 - r_f, r_2 - r_f, \dots, r_n - r_f)^\top$$

- El modelo de un índice postula que este vector de rendimientos en exceso se puede representar mediante el sistema de ecuaciones

$$r_i - r_f = \gamma_i + \beta_i(r_m - r_f) + \epsilon_i, \quad i = 1, 2, \dots, n, \quad (4)$$

donde r_m denota el rendimiento del índice de mercado, γ_i y β_i son parámetros específicos del activo i

- Los coeficientes γ_i y β_i cambian con respecto a cada rendimiento r_i
- ϵ_i representa la componente residual idiosincrático del activo i

Modelo de un índice

En notación vectorial, el sistema completo se puede escribir como

$$\mathbf{r} - r_f \mathbf{1} = \boldsymbol{\gamma} + \boldsymbol{\beta}(r_m - r_f) + \boldsymbol{\epsilon}, \quad (5)$$

donde

- $\boldsymbol{\gamma} = (\gamma_1, \dots, \gamma_n)^\top$ denota el vector de interceptos.
- $\boldsymbol{\beta} = (\beta_1, \dots, \beta_n)^\top$ es el vector de sensibilidades sistemáticas.
- $\boldsymbol{\epsilon} = (\epsilon_1, \dots, \epsilon_n)^\top$ representa el vector de rendimientos residuales.

Modelo de un índice

Las suposiciones del modelo de un índice, formalmente:

- (1) $\mathbb{E}(\epsilon_i) = 0$ para todo $i = 1, \dots, n$.
- (2) $Cov(\epsilon_i, r_m) = 0$ para todo i .
- (3) No correlación entre residuales de activos distintos: $Cov(\epsilon_i, \epsilon_j) = 0$ para todo $i \neq j$.
- (4) Homoscedasticidad en el tiempo (se supone frecuentemente pero no estrictamente necesaria), $Var(\epsilon_i) = \sigma_{\epsilon_i}^2$ constante a través del tiempo.

La tercera suposición es la hipótesis distintiva (y restrictiva) del modelo de un índice

Modelo de un índice

- La suposición se puede expresar mediante la estructura de la matriz de covarianzas de los residuales

$$\Sigma_{\epsilon} = \begin{pmatrix} \sigma_{\epsilon_1}^2 & 0 & \cdots & 0 \\ 0 & \sigma_{\epsilon_2}^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{\epsilon_n}^2 \end{pmatrix}$$

El vector de rendimientos esperados en exceso está dado por

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = \boldsymbol{\gamma} + \boldsymbol{\beta}[\mathbb{E}(r_m) - r_f],$$

donde se utiliza el hecho de que $\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$.

Modelo de un índice

Proposición:

Sean Σ la matriz de covarianzas de $\mathbf{r}$ y Σ_ϵ la matriz de covarianzas de $\epsilon_1, \dots, \epsilon_n$, respectivamente.

(a) Si se satisface el modelo (5), entonces

$$\Sigma = \sigma_m^2 \boldsymbol{\beta} \boldsymbol{\beta}^\top + \Sigma_\epsilon,$$

donde $\sigma_m^2 = \text{Var}(r_m)$.

(b) Si se satisface el modelo (5), entonces para cualesquiera dos activos $i \neq j$,

$$\rho_{i,j} = \rho_{i,m} \cdot \rho_{j,m}$$

Modelo de un índice

- Escribiendo explícitamente la expresión matricial, la matriz de covarianzas Σ toma la estructura

$$\Sigma = \begin{pmatrix} \beta_1^2 \sigma_m^2 + \sigma_{\epsilon_1}^2 & \beta_1 \beta_2 \sigma_m^2 & \cdots & \beta_1 \beta_n \sigma_m^2 \\ \beta_2 \beta_1 \sigma_m^2 & \beta_2^2 \sigma_m^2 + \sigma_{\epsilon_2}^2 & \cdots & \beta_2 \beta_n \sigma_m^2 \\ \vdots & \vdots & \ddots & \vdots \\ \beta_n \beta_1 \sigma_m^2 & \beta_n \beta_2 \sigma_m^2 & \cdots & \beta_n^2 \sigma_m^2 + \sigma_{\epsilon_n}^2 \end{pmatrix}$$

- Nótese que las entradas diagonales tienen la forma $\Sigma_{ii} = \sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma_{\epsilon_i}^2$, recuperando la descomposición familiar de la varianza total en componentes sistemático e idiosincrático.
- Los elementos fuera de la diagonal, i.e. las covarianzas entre activos distintos, también toman una forma simple

$$\Sigma_{ij} = \text{Cov}(r_i - r_f, r_j - r_f) = \beta_i \beta_j \sigma_m^2, \quad i \neq j.$$

Módelo de un índice

- (a) Bajo el modelo (4) la varianza del rendimiento de cada activo i satisface

$$Var(r_i) = Var(r_f + \gamma_i + \beta_i(r_m - r_f) + \epsilon_i) = Var(\beta_i r_m + \epsilon_i)$$

Es decir, que para cualesquiera $i, j \in \{1, \dots, n\}$

$$\sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma_{\epsilon_i}^2, \quad \sigma_j^2 = \beta_j^2 \sigma_m^2 + \sigma_{\epsilon_j}^2$$

También bajo el modelo (4)

$$Cov(r_m, r_i) = Cov(r_M, r_f + \gamma_i + \beta_i(r_m - r_f) + \epsilon_i) = Cov(r_m, \beta_i r_m + \epsilon_i)$$

Es decir, que para cualesquiera $i, j \in \{1, \dots, n\}$

$$Cov(r_i, r_m) = \beta_i \sigma_m^2, \quad Cov(r_j, r_m) = \beta_j \sigma_m^2$$

Módulo de un índice

Entonces, la correlación entre el rendimiento del activo i y el rendimiento del activo de referencia es

$$\rho_{i,m} = \frac{Cov(r_i, r_m)}{\sigma_i \sigma_m} = \frac{\beta_i \sigma_m^2}{\sigma_m \sqrt{\beta_i \sigma_m^2 + \sigma_{\epsilon_i}^2}} = \frac{\beta_i \sigma_m}{\sqrt{\beta_i \sigma_m^2 + \sigma_{\epsilon_i}^2}}$$

Además,

$$\begin{aligned} Cov(r_i, r_j) &= \\ Cov(r_f + \gamma_i + \beta_i(r_m - r_f) + \epsilon_i, r_f + \gamma_j + \beta_j(r_m - r_f) + \epsilon_j) &= \\ = Cov(\beta_i r_m + \epsilon_i, \beta_j r_m + \epsilon_j) &= \\ = Cov(\beta_i r_m, \beta_j r_m) + Cov(\beta_i r_m, \epsilon_j) + Cov(\epsilon_i, \beta_j r_m) + Cov(\epsilon_i, \epsilon_j) &= \\ = \beta_i \beta_j Cov(r_m, r_m) = \beta_i \beta_j Var(r_m) \end{aligned}$$

Módulo de un índice

(b) La correlación entre cualesquiera dos activos,

$$\begin{aligned}\rho_{i,j} &= \frac{Cov(r_i, r_j)}{\sigma_i \sigma_j} = \frac{\beta_i \beta_j \sigma_m^2}{\sqrt{\beta_i \sigma_m^2 + \sigma_{\epsilon_i}^2} \sqrt{\beta_j \sigma_m^2 + \sigma_{\epsilon_j}^2}} \\ &= \frac{\beta_i \sigma_m \beta_j \sigma_m}{\sqrt{\beta_i \sigma_m^2 + \sigma_{\epsilon_i}^2} \sqrt{\beta_j \sigma_m^2 + \sigma_{\epsilon_j}^2}} = \rho_{i,m} \rho_{j,m}\end{aligned}$$

Es decir, la correlación entre activos está determinada simplemente por la correlación con el rendimiento del activo de referencia.

Modelo de un índice

- Esta expresión muestra que la covarianza entre cualesquiera dos activos distintos depende exclusivamente de sus betas respectivos y de la varianza del mercado.
- No hay términos adicionales que reflejen covariaciones idiosincráticas directas entre activos.
- Esto quiere decir que toda la covariación se canaliza a través del factor de mercado común.
- En el marco general sin alguna estructura impuesta, la matriz de covarianzas simétrica Σ tiene $\frac{n(n+1)}{2}$ parámetros distintos: n varianzas en la diagonal principal más $\frac{n(n-1)}{2}$ covarianzas únicas en la parte triangular superior (o inferior).
- Bajo la estructura impuesta en el modelo de un índice, el número de parámetros se reduce a $2n + 1$: n elementos del vector β , n elementos diagonales de Σ_ϵ (las varianzas idiosincráticas), y un único parámetro escalar σ_m^2 .

Modelo de un índice

¿Tienen todo para echar a andar el modelo de un índice?

Eigenportafolios

Resultados necesarios:

- Como Σ es positivo-definida, sus eigenvalores son positivos.
- Como Σ es positivo-definida, tiene un conjunto de n eigenvectores linealmente independientes que forman una base para $\mathbb{R}^n$.
- Como Σ es simétrica, sus eigenvectores no sólo son diferentes, sino que son ortogonales entre sí.
- Se supondrá que la matriz de covarianzas Σ tiene una descomposición espectral

$$\Sigma = E \Lambda E^T$$

Matriz de eigenvectores
Obj: ¿Podría truncarse algo de ahí?

- donde $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ con $\lambda_1 \geq \dots \geq \lambda_n > 0$
- $E = [e_1 | \dots | e_n]$ es una matriz ortogonal cuyas columnas son los eigenvectores de Σ .

El Algebra lineal nos dice que si:
 $\Sigma = \lambda_1 \Sigma_1 + \lambda_2 \Sigma_2 + \dots + \lambda_k \Sigma_k$
ten Espectral.

Eigenportafolios

Por lo tanto que
garantiza que con este portafolio
seguros en la zona de
máximo Sharpe-ratio.

Definición (Eigenportafolios):

Supóngase que se tienen n activos riesgosos, con rendimientos

$\mathbf{r} = (r_1, r_2, \dots, r_n)^\top$, valores esperados

$\mathbb{E}(\mathbf{r}) = (\mathbb{E}(r_1), \mathbb{E}(r_2), \dots, \mathbb{E}(r_n))^\top$ y matriz de covarianzas Σ . Sean $\mathbf{e}_1, \dots, \mathbf{e}_n$ los eigenvectores de Σ . Se define al vector de ponderaciones

$$\mathbf{z}^{(i)} := \frac{\mathbf{e}_i}{\mathbf{1}^\top \mathbf{e}_i}$$

Estoy forzado
a que las enteras
del i-ésimo vector
sumen 1

Se dice que el portafolio con rendimiento

$$r_e^{(i)} = \left(\mathbf{z}^{(i)} \right)^\top \mathbf{r} = \mathbf{r}^\top \mathbf{z}^{(i)}$$

es el i -ésimo eigenportafolio.

Es decir, los eigenportafolios son simplemente portafolios que se basan en un re-escalamiento de los eigenvectores de la matriz de covarianzas.

Eigenportafolios

Proposición:

- (a) Sea λ_i el correspondiente eigenvalor del eigenvector e_i . Entonces, la varianza del rendimiento del i -ésimo eigenportafolio es

$$Var(r_e^{(i)}) = \frac{\lambda_i}{(\mathbf{1}^\top e_i)^2}$$

$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$
↗ la varianza
va decreciendo.

- (b) La covarianza entre los rendimientos de dos eigenportafolios diferentes es 0, i.e.

$$Cov(r_e^{(i)}, r_e^{(j)}) = 0, \quad i \neq j$$

Eigenportafolios

Proposición:

- (c) La covarianza entre el rendimiento del activo j y el rendimiento del i -ésimo eigenportafolio es

$$\text{Cov} \left(r_j, r_e^{(i)} \right) = \frac{\lambda_i}{\mathbf{1}^\top \mathbf{e}_i} e_j^{(i)} = \text{Var} \left(r_e^{(i)} \right) (\mathbf{1}^\top \mathbf{e}_i) e_j^{(i)},$$

donde $e_j^{(i)}$ es la j -ésima entrada del eigenvector i .

Demostración: Recordando $r = \underline{\alpha}^\top \mathbf{r}$ s.a. $\underline{\alpha}^\top \mathbf{1} = 1$ $\underline{z}^{(i)} = \frac{\mathbf{e}_i}{\mathbf{1}^\top \mathbf{e}_i}$

(a)

$$\begin{aligned} \text{Var}(r_e^{(i)}) &= \text{Var}((\underline{z}^{(i)})^\top \mathbf{r}) = (\underline{z}^{(i)})^\top \underline{\Sigma} \underline{z}^{(i)} = \frac{1}{\mathbf{1}^\top \mathbf{e}_i} (\underline{z}^{(i)})^\top \underline{\Sigma} \mathbf{e}_i \\ &\stackrel{\text{def}}{=} \frac{1}{\mathbf{1}^\top \mathbf{e}_i} (\underline{z}^{(i)})^\top \lambda_i \mathbf{e}_i = \frac{\lambda_i}{(\mathbf{1}^\top \mathbf{e}_i)^2} \mathbf{e}_i^\top \mathbf{e}_i = \frac{\lambda_i}{(\mathbf{1}^\top \mathbf{e}_i)^2} \|\mathbf{e}_i\|^2 \\ &= \frac{\lambda_i}{(\mathbf{1}^\top \mathbf{e}_i)^2} \end{aligned}$$

Eigenportafolios

$$\left. \begin{aligned} r_a &= \underline{a}^\top \underline{r}, \quad r_w := \underline{w}^\top \underline{r} \\ \text{Cov}(r_a, r_w) &= \underline{a}^\top \underline{\Sigma} \underline{w} \end{aligned} \right\} \text{Enrique}$$

(b)

$$\begin{aligned} \text{Cov}(r_e^{(i)}, r_e^{(j)}) &= \text{Cov}\left((\underline{z}^{(i)})^\top \underline{r}, (\underline{z}^{(j)})^\top \underline{r}\right) = (\underline{z}^{(i)})^\top \underline{\Sigma} \underline{z}^{(j)} \\ &\stackrel{\text{def } \underline{z}^{(i)}}{=} \frac{1}{(\mathbf{1}^\top \underline{e}_i)(\mathbf{1}^\top \underline{e}_j)} \underline{e}_i^\top \underline{\Sigma} \underline{e}_j = \frac{\lambda_j}{(\mathbf{1}^\top \underline{e}_i)(\mathbf{1}^\top \underline{e}_j)} \underline{e}_i^\top \underline{e}_j = 0 \end{aligned}$$

↙
eigenvector
son orto
gonales

(c) Tarjeta

$$\text{Cov}(r_j, r_e^{(i)}) = \text{Cov}\left(\underline{\alpha}^\top \underline{r}, (\underline{z}^{(i)})^\top \underline{r}\right) = \underline{\alpha}^\top \underline{\Sigma} \underline{z}^{(i)},$$

donde $\underline{\alpha}$ es un vector tal que $\alpha_j = 1$ y $\alpha_k = 0, k \neq j$. Entonces,

$$\begin{aligned} \text{Cov}(r_j, r_e^{(i)}) &= \underline{\alpha}^\top \underline{\Sigma} \left(\frac{\underline{e}_i}{\mathbf{1}^\top \underline{e}_i} \right) = \frac{\underline{\alpha}^\top \lambda_i \underline{e}_i}{\mathbf{1}^\top \underline{e}_i} \\ &= \frac{\lambda_i}{\mathbf{1}^\top \underline{e}_i} \underline{\alpha}^\top \underline{e}_i = \frac{\lambda_i}{\mathbf{1}^\top \underline{e}_i} e_j^{(i)} \end{aligned}$$

Eigenportafolios

- El portafolio de tangencia o de máximo Sharpe-ratio es aquel que maximiza el exceso de rendimiento esperado con respecto a su desviación, i.e. maximiza el Sharpe-ratio (como su nombre lo dice).

$$\alpha_T = \arg \max \frac{\alpha^\top (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}{\sqrt{\alpha^\top \Sigma \alpha}}$$

sujeto a que $\alpha^\top \mathbf{1} = 1$.

- Con Enrique ya demostraron que el vector de ponderaciones de este portafolio de máximo Sharpe-ratio es

$$\alpha_T = \frac{\Sigma^{-1} (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}{\mathbf{1}^\top \Sigma^{-1} (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}$$

Waaaaa!!

esto podría ser complicado y agregar más.

Eigenportafolios

Obj: Garantizar que si tenemos Σ seguimos en la zona de máximo Sharpe ratio (i.e. en la zona de tangencia)

Resultado importante.

Proposición: 😊

Si el vector de primas de riesgo es un múltiplo escalar del i -ésimo eigenvector de Σ y la suma de las entradas de dicho vector de primas de riesgo escalado es positivo, i.e.

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} \in \text{span}(\mathbf{e}_i)$$

$$\underbrace{\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}}_{\text{Vector de primas de riesgo}} = c \cdot \mathbf{e}_i, \quad c \in \{a \neq 0 : a \mathbf{1}^\top \mathbf{e}_i > 0\}$$

Entonces el portafolio de tangencia es exactamente el i -ésimo eigenportafolio i.e.

$$\alpha_T \equiv \mathbf{z}^{(i)} = \frac{\mathbf{e}_i}{\mathbf{1}^\top \mathbf{e}_i}$$

Eigenportafolios

Demostración: $\mathbb{E}(r - r_f \mathbf{1}) = c \cdot e_i$

Sustituyendo $c \cdot e_i$ en la expresión para el portafolio de tangencia, se tiene que

$$\begin{aligned} \alpha_T &= \frac{\Sigma^{-1}(\mathbb{E}(r) - r_f \mathbf{1})}{\mathbf{1}^\top \Sigma^{-1}(\mathbb{E}(r) - r_f \mathbf{1})} \\ &\stackrel{\text{Hpt}}{=} \frac{\Sigma^{-1}(c \cdot e_i)}{\mathbf{1}^\top \Sigma^{-1}(c \cdot e_i)} \stackrel{\text{ant}}{=} \frac{\Sigma^{-1} e_i}{\mathbf{1}^\top \Sigma^{-1} \cdot e_i} \\ &\stackrel{\checkmark}{=} \frac{\lambda^{-1} e_i}{\mathbf{1}^\top \lambda^{-1} e} = \frac{e_i}{\mathbf{1}^\top e_i} = z^{(i)}. \end{aligned}$$

$$\begin{aligned} \Sigma e_i &= \lambda_i e_i \\ \stackrel{??}{=} \Sigma^{-1} e_i &= \lambda_i^{-1} e_i? \end{aligned}$$

$$\begin{aligned} \Sigma e_i &= \lambda_i e_i \Rightarrow \\ \Sigma^{-1} \Sigma e_i &= \Sigma^{-1} \lambda_i e_i \\ \Rightarrow \Sigma^{-1} \lambda_i e_i &= \lambda_i^{-1} e_i \\ \Rightarrow \Sigma^{-1} e_i &= \lambda_i^{-1} e_i \checkmark \end{aligned}$$

Eigenportafolios

→ otra proposición importante

Proposición: es

Si el i -ésimo eigenportafolio es el portafolio de tangencia, entonces el vector de rendimientos esperados de los n activos satisface

$$\mathbb{E}(\mathbf{r}) = r_f \mathbf{1} + c \mathbf{e}_i,$$

← $\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = c \cdot \mathbf{e}_i$

para algún escalar $c \in \{a \neq 0 : a \mathbf{1}^\top \mathbf{e}_i > 0\}$

Demostración: ltp $\mathbf{z}^{(i)} = \underline{\alpha}^\top$

Como $\mathbf{z}^{(i)}$ es el vector de ponderaciones del portafolio de tangencia, entonces

$$\mathbf{z}^{(i)} = \frac{\mathbf{e}_i}{\mathbf{1}^\top \mathbf{e}_i} = \frac{\Sigma^{-1}(\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}{\mathbf{1}^\top \Sigma^{-1}(\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})} = \underline{\alpha}^\top$$

Eigenportafolios

Multiplicando por la izquierda ambos lados por Σ ,

$$\frac{\Sigma \mathbf{e}_i}{\mathbf{1}^\top \mathbf{e}_i} = \frac{\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})} \quad \checkmark$$

Por tanto,

$$\underbrace{\lambda_i \mathbf{e}_i}_{\substack{\in \mathbb{R} \\ 1 \times n \times (n \times 1)}} = \underbrace{\frac{\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}}_{\substack{\mathbb{R} \\ (1 \times n) \times (n \times n) (n \times 1)}} \quad \rightarrow \mathbb{R}$$

Es decir, existe $\kappa \in \mathbb{R}$

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = \kappa \lambda_i \mathbf{e}_i$$

$$\kappa := \frac{\mathbf{1}^\top \Sigma^{-1} (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}{\mathbf{1}^\top \mathbf{e}_i}$$

Haciendo $c := \kappa \lambda_i$, entonces $\mathbb{E}(\mathbf{r}) = r_f \mathbf{1} + c \mathbf{e}_i$

Eigenportafolios

- Con la proposición ~~11~~ se establece que si el portafolio de tangencia es un eigenportafolio, entonces el vector de primas de riesgo es un múltiplo de este portafolio.
- Con la proposición ~~12~~ se puede determinar con exactitud al vector de rendimientos esperados en el caso de que un inversionista que maximice el Sharpe-ratio tenga un único eigenportafolio.
- Es raro que sólo se necesite un eigenportafolio
- En general, los inversionistas tienen combinaciones de eigenportafolios. Entonces, se quiere generalizar esta idea para considerar el caso de un portafolio de eigenportafolios.

Eigenportafolios

Proposición:

Si el vector de primas de riesgo se expresa a partir de los eigenvectores de Σ como

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = \sum_{j=1}^n c_j \mathbf{e}_j \quad \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$$

y se satisface que $\mathbf{1}^\top \Sigma^{-1} \mathbb{E}(\mathbf{r}) > 0$, entonces el portafolio de tangencia tiene ponderaciones

$$\alpha_T = \frac{\sum_{j=1}^n \frac{c_j}{\lambda_j} \mathbf{e}_j}{\sum_{j=1}^n \frac{c_j}{\lambda_j} \mathbf{1}^\top \mathbf{e}_j} = \frac{1}{\sum_{j=1}^n \frac{c_j}{\lambda_j} \mathbf{1}^\top \mathbf{e}_j} \left(\frac{c_1}{\lambda_1} \mathbf{e}_1 + \dots + \frac{c_n}{\lambda_n} \mathbf{e}_n \right)$$

Eigenportafolios

Demostración:

A partir de la expresión para las ponderaciones del portafolio de tangencia,

$$\begin{aligned}\alpha_T &\stackrel{\text{def}}{=} \frac{\Sigma^{-1}(\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}{\mathbf{1}^\top \Sigma^{-1}(\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})} \stackrel{\text{HPT}}{=} \frac{\Sigma^{-1} \sum_{j=1}^n c_j \mathbf{e}_j}{\mathbf{1}^\top \Sigma^{-1} \sum_{j=1}^n c_j \mathbf{e}_j} \\ &\stackrel{\text{ant}}{=} \frac{\sum_{j=1}^n c_j \Sigma^{-1} \mathbf{e}_j}{\sum_{j=1}^n c_j \mathbf{1}^\top \Sigma^{-1} \mathbf{e}_j} = \frac{\sum_{j=1}^n c_j \lambda_j^{-1} \mathbf{e}_j}{\sum_{j=1}^n c_j \mathbf{1}^\top \lambda_j^{-1} \mathbf{e}_j} \\ &\stackrel{\text{cmt.}}{=} \frac{\sum_{j=1}^n \frac{c_j}{\lambda_j} \mathbf{e}_j}{\sum_{j=1}^n \frac{c_j}{\lambda_j} \mathbf{1}^\top \mathbf{e}_j}.\end{aligned}$$


Eigenportafolios

- Una consecuencia de esta proposición es que el vector de primas de riesgo está en el mismo subespacio del eigenspacio que resulta del portafolio de tangencia.
- Si el vector de primas de riesgo es una combinación lineal de un subconjunto de eigenvectores, entonces el portafolio de tangencia será un promedio ponderado de subconjunto correspondiente de eigenportafolios.

“ La tangencia se conserva si sumamos adecuadamente los eigenvectores ”

“ El Sharpe-ratio sigue siendo máximo si sumamos adecuadamente los eigenvectores ”

Eigenportafolios

Proposición:

Supóngase que un vector α_T se escribe como $\alpha_T = \sum_{j=1}^n c_j \mathbf{e}_j$

(a) Si el vector α_T es un vector de ponderaciones, i.e.

$$\mathbf{1}^\top \alpha_T = \sum_{j=1}^n c_j \mathbf{1}^\top \mathbf{e}_j = 1,$$

que lleve a un portafolio de máximo Sharpe-ratio, entonces, el vector de rendimientos esperados de los activos riesgosos satisface

$$\mathbb{E}(\mathbf{r}) = r_f \mathbf{1} + \theta \sum_{j=1}^n c_j \lambda_j \mathbf{e}_j,$$

donde θ es una constante tal que $\mathbf{1}^\top \Sigma^{-1} (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}) > 0$

Eigenportafolios

Proposición (continuación):

- (b) Para un valor específico de $\mathbb{E}(\mathbf{r})$, θ representa el cociente entre la prima de riesgo del portafolio de mínima varianza y la varianza del portafolio de mínima varianza, i.e.

$$\theta = \frac{\mathbb{E}(r_{mv}) - r_f}{\sigma_{mv}^2}$$

Eigenportafolios

Demostración:

Como el portafolio de máximo Sharpe-ratio se puede escribir como una combinación lineal de los eigenvectores de Σ , entonces

$$\Sigma^{-1}(\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}) \propto \sum_{j=1}^n c_j \mathbf{e}_j$$

Entonces, existe $\theta \in \mathbb{R}$ tal que

$$\Sigma^{-1}(\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}) = \theta \sum_{j=1}^n c_j \mathbf{e}_j$$

Multiplicando por la izquierda por Σ ambos lados

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = \theta \Sigma \left[\sum_{j=1}^n c_j \mathbf{e}_j \right] = \theta \sum_{j=1}^n c_j \Sigma \mathbf{e}_j = \theta \sum_{j=1}^n c_j \lambda_j \mathbf{e}_j$$

Eigenportafolios

$$\begin{aligned}\alpha_{mv}^\top (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}) &= \left(\frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \right)^\top (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}) \\ &= \frac{\mathbf{1}^\top \Sigma^{-1} (\theta \sum_{j=1}^n c_j \lambda_j \mathbf{e}_j)}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \\ &= \frac{\theta \sum_{j=1}^n c_j \lambda_j \mathbf{1}^\top \Sigma^{-1} \mathbf{e}_j}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} = \frac{\theta \sum_{j=1}^n c_j \lambda_j \mathbf{1}^\top (1/\lambda_j) \mathbf{e}_j}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \\ &= \frac{\theta \sum_{j=1}^n c_j \mathbf{1}^\top \mathbf{e}_j}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} = \sigma_{mv}^2 \cdot \theta \sum_{j=1}^n c_j \mathbf{1}^\top \mathbf{e}_j = \sigma_{mv}^2 \cdot \theta\end{aligned}$$

Entonces

$$\theta = \frac{\alpha_{mv}^\top (\mathbb{E}(\mathbf{r}) - r_f \mathbf{1})}{\sigma_{mv}^2} = \frac{\alpha_{mv}^\top \mathbb{E}(\mathbf{r}) - r_f \alpha_{mv}^\top \mathbf{1}}{\sigma_{mv}^2} = \frac{\mathbb{E}(r_{mv}) - r_f}{\sigma_{mv}^2}$$

Eigenportafolios

- El inciso (a) de esta proposición establece que

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = \theta \sum_{j=1}^n c_j \lambda_j \mathbf{e}_j,$$

importancia

i.e. se puede obtener la “importancia” del vector de primas de riesgo implicada en cada dirección de los n eigenvectores de Σ .

- Esta “importancia” depende del tamaño de los eigenvalores

$$\lambda_1 > \lambda_2 > \dots > \lambda_n > 0$$

- Para simplificar la notación,

$$\mathbb{E}(\mathbf{r}) - r_f \mathbf{1} = \sum_{j=1}^n c_j \mathbf{e}_j,$$

no quise simplificar



$$= \sum_{j=1}^K c_j \mathbf{e}_j$$

$K \ll n$
i don't not

con $c_j \leftarrow \theta \cdot c_j \cdot \lambda_j$

Eigenportafolios

Yo quiero poner al vector $E(R) - r_f \mathbb{1}$
como comb. lineal de los eigenvectores
PERO NO DE TODOS

$$E(R) - r_f \mathbb{1} = \sum_{i=1}^K c_i e_i \quad K < n$$

Se considerarán dos metodologías:

- 1 **Método de corte espectral:** Usar los primeros K eigenvectores para aproximar las primas de riesgo — $E(R) - r_f \mathbb{1}$
- 2 **Método de selección espectral:** Los eigenvectores que se usan para aproximar el vector de primas de riesgo no corresponden necesariamente a eigenvalores muestrales consecutivos.

a.k.a PCA regression

a.k.a regression LASSO

Método de corte espectral

- Para disminuir el impacto de los errores de estimación sobre $\hat{\alpha}_T$, se propone un método de aproximar $\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}$ en el espacio generado por los primeros K eigenvectores de $\hat{\Sigma}$
- Si la aproximación es buena, se usa para reemplazar $\mathbb{E}(\mathbf{r}) - r_f \mathbf{1}$.
- Sólo se usan los primeros K eigenvalores y eigenvectores en el cálculo de $\hat{\alpha}_T$
- Se evitan los errores de estimación de los $n - K$ eigenvalores más pequeños y sus correspondientes eigenvectores.
- Se encontrará la aproximación óptima de $\boldsymbol{\mu} - r_f \mathbf{1}$ en el espacio de dimensión K que tenga distancia cuadrática al vector original mínima.

Evita con todas sus fuerzas
a regresión lineal (mínimos cuadrados)

Método de corte espectral

- Sea $\sum_{j=1}^K c_j \hat{e}_j$ el vector de primas de riesgo en el espacio de dimensión K .
- El objetivo es encontrar los valores de $c_1, \dots, c_K$ que resuelvan del problema de optimización

$$\min_{c_1, \dots, c_K} \left\| \underbrace{\mu - r_f \mathbf{1}}_y - \sum_{j=1}^K \underbrace{c_j}_{\text{beta de regresión}} \underbrace{\hat{e}_j}_{\chi_n} \right\|^2 \quad (6)$$

Método de corte espectral

- Sea $\hat{\mathbf{E}}_K := [\hat{\mathbf{e}}_1 | \dots | \hat{\mathbf{e}}_K]$ la matriz cuyas columnas son los primeros K eigenvectores muestrales, i.e. $\hat{\mathbf{E}}_K \in \mathbb{R}^{n \times K}$
- $\hat{\mathbf{\Lambda}}_K := \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_K) \in \mathbb{R}^{K \times K}$
- $\mathbf{c} = (c_1, \dots, c_K)^\top \in \mathbb{R}^{K \times 1}$ el vector solución que se quiere encontrar
- El problema (6) es un clásico problema de mínimos cuadrados, cuya solución es

$$\mathbf{c} = \hat{\mathbf{E}}_K^\top (\boldsymbol{\mu} - r_f \mathbf{1})$$

- El vector de primas de riesgo aproximado es

$$\boldsymbol{\mu}_K^* - r_f \mathbf{1} := \hat{\mathbf{E}}_K \hat{\mathbf{E}}_K^\top (\boldsymbol{\mu} - r_f \mathbf{1}) \quad (7)$$

¿cómo lo echamos a order?

$$\begin{bmatrix} E(r_1) - r_f \\ E(r_2) - r_f \\ \vdots \\ E(r_n) - r_f \end{bmatrix} = \begin{bmatrix} c_1 e_{11} + c_2 e_{12} + \dots + c_k e_{1k} \\ c_1 e_{21} + c_2 e_{22} + \dots + c_k e_{2k} \\ \vdots \\ c_1 e_{n1} + c_2 e_{n2} + \dots + c_k e_{nk} \end{bmatrix}$$

$n \times 1$

$\Rightarrow$ Regresión clásica.

$$y = \begin{bmatrix} E(r_1) - r_f \\ \vdots \\ E(r_n) - r_f \end{bmatrix} \quad x_1 = \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix}, \quad x_2 = \begin{bmatrix} e_2 \\ \vdots \\ e_n \end{bmatrix}$$

¡ Regresión clásica!

$$\dots x_k = \begin{bmatrix} e_k \\ \vdots \\ e_n \end{bmatrix}$$

Método de corte espectral

- Reemplazando $\mu - r_f \mathbf{1}$ por $\mu_K^* - r_f \mathbf{1}$ se obtiene el siguiente aproximado del portafolio de tangencia,

$$\hat{\alpha}_T^{[K]} := \frac{\hat{\Sigma}_K^{-1} (\mu - r_f \mathbf{1})}{\mathbf{1}^\top \hat{\Sigma}_K^{-1} (\mu - r_f \mathbf{1})},$$

ponderación
superstatumk
más limpia

donde $\hat{\Sigma}_K^{-1} = \hat{\mathbf{E}}_K \hat{\Lambda}_K^{-1} \hat{\mathbf{E}}_K^\top$.

- $\hat{\alpha}_T^{[1]}$ es el vector de ponderación usando sólo primer eigenvector.
- $\hat{\alpha}_T^{[2]}$ es el vector de ponderación usando primer y segundo eigenvectores.
- $\hat{\alpha}_T^{[K]}$ es el vector de ponderación usando primer, segundo, ... y K -ésimo eigenvectores.

Método de corte espectral

① Como dice PCA $\hat{\sigma}$ con la varianza acumulada
o.k.a el diagrama de codo
(scree plot)

② Fuerza bruta

$$y \sim e_1 \rightarrow AIC_1, BIC_1, R_1^2$$

$$y \sim e_1 + e_2 \rightarrow AIC_2, BIC_2, R_2^2$$

• ¿Cómo seleccionar K ?

$$y \sim e_1 + e_2 + e_3 \rightarrow AIC_3, BIC_3, R_3^2$$

$\vdots$

$$y \sim e_1 + e_2 + \dots + e_n \rightarrow AIC_n, BIC_n, R_n^2$$

y quedarse con la K que tenga los mejores
 AIC , BIC y/o R^2

Método de corte espectral

- **Otra forma:** Especificar el error relativo de aproximación máximo que se puede tolerar, δ (e.g. 20%, 15%, 10%) y seleccionar el mínimo K tolerable.
↳ lo pongo yo.
- Bajo este criterio, el número de eigenvectores que se debe utilizar es

$$K_\delta := \min \left\{ K : \frac{\|(\boldsymbol{\mu} - r_f \mathbf{1}) - (\boldsymbol{\mu}_K^* - r_f \mathbf{1})\|_2}{\|\boldsymbol{\mu} - r_f \mathbf{1}\|_2} \leq \delta \right\}$$

- El problema se convierte ahora a seleccionar δ y ocupar el K correspondiente.

Método de selección espectral

al vector de primas de riesgo.

- La idea consiste en aproximar los rendimientos excedentes esperados utilizando eigenvectores no necesariamente consecutivos.
- PEEEEEEERO poniendo atención en los eigenvectores finales.
- Se plantea el siguiente problema de optimización penalizada para aproximar $\mu - r_f \mathbf{1}$

$$\min_{c_1, \dots, c_n} \left\{ \left\| \mu - r_f \mathbf{1} - \sum_{i=1}^n c_i \mathbf{e}_i \right\|_2^2 + \gamma \sum_{i=1}^n \frac{|c_i|}{\sqrt{\hat{\lambda}_i}} \right\} \quad (8)$$

hyper-parameter.

- La idea de (8) es la misma que la de (6): Encontrar una aproximación adecuada del vector de primas de riesgo esperadas $\mu - r_f \mathbf{1}$ en un espacio de menor dimensión.
- Pero acá se usa una penalización tipo LASSO para incentivar la simplicidad en la solución y “quitar” eigenvectores que no proporcionan información suficiente.

Método de selección espectral

- Como es probable que los eigenvalores y eigenvectores muestrales de la cola estén peor estimados en comparación con los primeros, se penaliza a los c_i para que los eigenvectores asociados con eigenvalores muestrales pequeños tengan menor probabilidad de ser incluidos en el conjunto de eigenvectores utilizados.
- La solución al problema de optimización en la ecuación (8) se puede escribir como


$$\mathbf{c}^* = \arg \min_{\mathbf{c}} \left\{ \left\| \boldsymbol{\mu} - r_f \mathbf{1} - \hat{\mathbf{E}} \mathbf{c} \right\|_2^2 + \gamma \sum_{i=1}^n \frac{|c_i|}{\sqrt{\hat{\lambda}_i}} \right\}$$

donde $\mathbf{c} = (c_1, \dots, c_n)^\top$.

Método de selección espectral

- El problema ahora es determinar γ , el parámetro de penalización.
- ¿Cómo lo encontramos? *→ cross-validation + grid search.*


Aproximación con eigenportafolios



$n = 75$

Tomado de la tesis de un estudiante

Aproximación con eigenportafolios



Aproximación con eigenportafolios

